

Statistique (MA101) Cours 6

ENSTA 1ère année

Christine Keribin

christine.keribin@math.u-psud.fr

Laboratoire de Mathématiques
Université Paris-Sud

2017-2018



Intervalle de confiance

Introduction
Définition
Construction

Le mot de la fin

Intervalle de confiance

Introduction

Définition

Construction

Le mot de la fin

Des tests aux intervalles de confiance

Soit le test $(H_0) : \mu = \mu_0$ contre $(H_1) : \mu \neq \mu_0$ de l'espérance d'une loi gaussienne $\mathcal{N}(\mu, \sigma^2)$ à variance connue. On ne peut rejeter (H_0) au niveau α si

$$|T(X)| = \left| \sqrt{n} \frac{\bar{X} - \mu_0}{\sigma} \right| \leq q_{1-\alpha/2}^*$$

soit

$$-q_{1-\alpha/2}^* \leq \sqrt{n} \frac{\bar{X} - \mu_0}{\sigma} \leq q_{1-\alpha/2}^*$$

qu'on peut aussi écrire

$$\underbrace{\bar{X} - q_{1-\alpha/2}^* \frac{\sigma}{\sqrt{n}}}_{\hat{\mu}_{inf}} \leq \mu_0 \leq \underbrace{\bar{X} + q_{1-\alpha/2}^* \frac{\sigma}{\sqrt{n}}}_{\hat{\mu}_{sup}}$$

et $1 - \alpha = \mathbb{P}(|T(X)| \leq q_{1-\alpha/2}^*) = \mathbb{P}([\hat{\mu}_{inf}; \hat{\mu}_{sup}] \ni \mu_0)$

- ▶ Ainsi, une valeur hypothétique de μ ne soit pas rejetée si elle est dans l'intervalle

$$IC(\mu) = [\hat{\mu}_{inf}; \hat{\mu}_{sup}]$$

- ▶ Cet intervalle $IC(\mu)$ aux bornes aléatoires est appelé **intervalle de confiance** de niveau $1 - \alpha$ de l'espérance μ inconnue
- ▶ Dans cet exemple, il y a équivalence pour μ entre prendre une valeur acceptée (H_0) dans le test de niveau α et le fait d'être situé dans l'intervalle de confiance de niveau (de confiance) $1 - \alpha$

Fournir un **intervalle** (**fourchette**) permet de prendre en compte la fluctuation d'échantillonnage plutôt que de donner une valeur ponctuelle $\hat{\mu}$

Définition

Soit $X = (X_1, \dots, X_n)$ un n -échantillon de loi \mathbb{P}_θ , où $\theta \in \Theta \subset \mathbb{R}$ est inconnu. Un **intervalle de confiance** de **niveau** $1 - \alpha$ pour θ est un intervalle $IC = [\hat{\theta}_{inf}(X), \hat{\theta}_{sup}(X)]$ dont les bornes sont **aléatoires**, telles que, pour tout $\theta \in \Theta$

$$\mathbb{P}_\theta(IC \ni \theta) \geq 1 - \alpha.$$

où α est "petit".

Une réalisation $[\hat{\theta}_{inf}(x), \hat{\theta}_{sup}(x)]$ est obtenue à partir des données $x = (x_1, \dots, x_n)$.

Retour sur l'exemple : $X_i \sim \mathcal{N}(\mu, \sigma^2)$, σ^2 connu.

- On choisit $0 \leq \alpha_1, \alpha_2 \leq \alpha$ tq $\alpha_1 + \alpha_2 = \alpha$ et soit q^* la fonction quantile de $\mathcal{N}(0, 1)$. Un intervalle de probabilité $1 - \alpha$ de $T = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$ est $[q_{\alpha_1}^*; q_{1-\alpha_2}^*]$

$$\mathbb{P}(q_{\alpha_1}^* < \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} < q_{1-\alpha_2}^*) = 1 - \alpha$$

- d'où un IC de niveau $1 - \alpha$ de μ

$$\mathbb{P}\left(\bar{X} - q_{1-\alpha_2}^* \frac{\sigma}{\sqrt{n}} < \mu < \bar{X} - q_{\alpha_1}^* \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha$$

$$IC = \left[\bar{X} - q_{1-\alpha_2}^* \frac{\sigma}{\sqrt{n}}; \bar{X} - q_{\alpha_1}^* \frac{\sigma}{\sqrt{n}}\right]$$

Intervalle de
confiance

Introduction

Définition

Construction

Le mot de la fin

Exemple : $X_i \sim \mathcal{N}(\mu, \sigma^2)$, $\sigma^2 = 1$, $n = 10$,
 $\bar{x} = 2.0686$.

Une infinité d'expression pour un même niveau $1 - \alpha$
 (ci-dessous, réalisations pour 4 couples (α_1, α_2))

	alpha1	alpha2	min	max	length
IC1	0.000	0.050	1.904	Inf	Inf
IC2	0.015	0.035	1.887	2.286	0.398
IC3	0.025	0.025	1.873	2.265	0.392
IC4	0.050	0.000	-Inf	2.233	Inf

- ▶ IC1 et IC4 sont des intervalles de confiance **unilatéraux**
- ▶ IC2 et IC3 sont **bilatéraux**
- ▶ IC3 est l'intervalle de confiance **symétrique**, de longueur minimale ici :

$$IC3(\mu) = \left[\bar{X} - q_{1-\alpha/2}^* \frac{\sigma}{\sqrt{n}}; \bar{X} + q_{1-\alpha/2}^* \frac{\sigma}{\sqrt{n}} \right]$$

Intervalle de
confiance

Introduction

Définition

Construction

Le mot de la fin

```
> mean(X)
[1] 2.0686
      alpha1 alpha2      min      max      length
IC3  0.025  0.025  1.873  2.265  0.392
```

- ▶ Interprétation **fausse** : θ appartient à $[1.873; 2.265]$ avec probabilité $1 - \alpha$.
- ▶ Interprétation **correcte** :
 - ↪ La vraie valeur de θ (inconnue) **appartient ou (exclus.) n'appartient pas** à l'intervalle observé $[1.873 ; 2.265]$.
 - ↪ Si on construit une centaine d'intervalles de confiance à partir d'une centaine de n -échantillons indépendants, **en moyenne** $100 \times \alpha$ IC observés **ne contiendront pas** θ
 - ↪ mais on ne sait pas lesquels...

Intervalle de
confiance

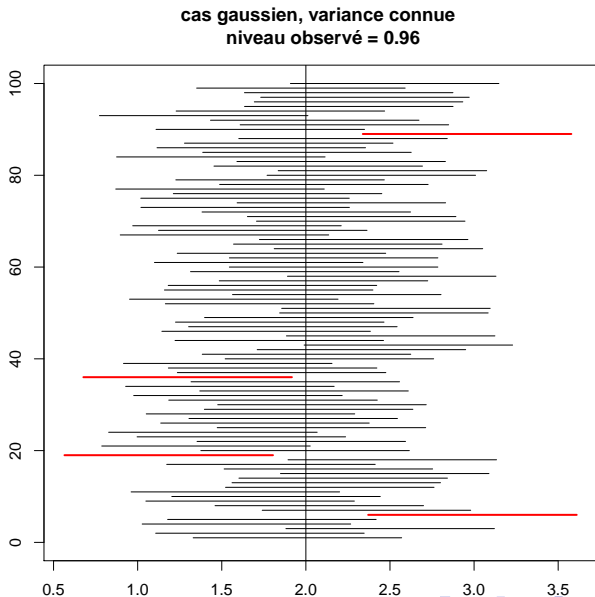
Introduction

Définition

Construction

Le mot de la fin

Exemple : IC de l'espérance à variance connue



- ▶ IC est d'autant plus large que α est petit.
 - ↪ A l'extrême, l'IC de niveau de confiance 1 contient toutes les valeurs possibles... mais n'est plus informatif !
- ▶ IC de l'espérance calculé précédemment est d'autant plus étroit que n est grand
 - ↪ Une construction d'IC est **convergente** si la différence de ses bornes tend en proba vers 0 avec n
- ▶ Choisir un estimateur de θ , dont on connaît la loi de probabilité pour tout θ , et le meilleur possible
 - ↪ à α et n fixés, l'IC est d'autant meilleur que sa longueur est faible (pour toute réalisation / en moyenne)

Inégalité **probabiliste**

Méthode **pivotale** :

- ▶ définir un estimateur $\hat{\theta}$ de θ
- ▶ trouver une statistique pivotale $T_n(\hat{\theta}, \theta)$ dont la loi ne dépend pas de θ
- ▶ exprimer les bornes de l'intervalle de confiance en fonction de T_n et de ses quantiles

Utiliser une **équivalence** Test - IC. Si $\mathcal{R}(\theta)$ est une région de rejet de niveau α , alors

$$IC(\theta) = \{\theta; \mathbb{I}_{X \in \mathcal{R}(\theta)} = 0\}$$

est un intervalle de confiance de niveau $1 - \alpha$.

Intervalle de
confiance

Introduction

Définition

Construction

Le mot de la fin

IC asymptotique :

- ▶ La loi de la statistique n'est pas connue à distance finie, mais tend asymptotiquement vers une loi pivotale.
- ▶ On construit l'IC comme si la loi à distance finie était la loi limite.
- ▶ le niveau de l'IC construit est **approximativement** $1 - \alpha$ à distance finie, et vaut **asymptotiquement** $1 - \alpha$
- ▶ l'approximation s'améliore avec n croissant.

Définition

Une suite d'intervalle de confiance IC_n de $\theta \in \mathbb{R}$ est de niveau asymptotique $1 - \alpha$ si, pour tout $\theta \in \Theta$, on a

$$\lim_{n \rightarrow \infty} \mathbb{P}(IC_n \ni \theta) = 1 - \alpha.$$

Exemple : IC de l'espérance θ d'une loi à variance inconnue

► TLC+Slutsky :

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \xrightarrow{\mathcal{P}} \sigma^2$$

$$T_n = \frac{\bar{X} - \theta}{S_n/\sqrt{n}} \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$$

d'où, avec q^* le quantile de $\mathcal{N}(0, 1)$ d'ordre $1 - \alpha/2$:

$$IC = \left[\bar{X} - q^* \frac{S_n}{\sqrt{n}}; \bar{X} + q^* \frac{S_n}{\sqrt{n}} \right] \text{ avec } \mathbb{P}(IC \ni \theta) \simeq 1 - \alpha$$

Tests et ICs **paramétriques usuels**

- ▶ Test d'une moyenne, d'une proportion, d'une variance
- ▶ Comparaison des moyennes de deux échantillons, comparaison de deux proportions, comparaison de deux variances

Tests d'**adéquation**

- ▶ hypothèse gaussienne : ex Shapiro-Wilks
- ▶ généraux pour les observations continues : Kolmogorov-Smirnov (test non paramétrique)
- ▶ observations discrètes : Khi-deux d'adéquation

Test de l'**indépendance** de deux facteurs

Test de corrélation entre deux variables...

Test de Student de comparaison de moyennes

- ▶ $X = (X_1, \dots, X_n) \sim \mathcal{N}(\mu_1, \sigma^2)$ et
 $Y = (Y_1, \dots, Y_m) \sim \mathcal{N}(\mu_2, \sigma^2)$ indépendants.
 μ_1, μ_2 et σ^2 sont inconnus.
- ▶ La variance est inconnue, et supposée identique dans les deux échantillons
- ▶ Alors, la statistique T définie par

$$T = \frac{\bar{Y} - \bar{X}}{\hat{\sigma} \sqrt{\frac{1}{n} + \frac{1}{m}}} \sim \mathcal{T}(n + m - 2)$$

$$\hat{\sigma}^2 = \frac{1}{n + m - 2} \left(\sum_{i=1}^n (X_i - \bar{X})^2 + \sum_{j=1}^m (Y_j - \bar{Y})^2 \right)$$

suit une loi de Student de paramètre $n + m - 2$.

Test de Student de comparaison de moyennes

- ▶ $(H_0) : \mu_1 = \mu_2$ contre $(H_1) : \mu_1 \neq \mu_2$: Région de rejet bilatérale de niveau α

$$\{|T| > q_{T(n+m-2)}^{1-\alpha/2}\}$$

- ▶ Un IC bilatère de niveau de confiance $1 - \alpha$

$$IC(\mu_2 - \mu_1) = \left[\bar{Y} - \bar{X} - q_{T(n+m-2)}^{1-\alpha/2} \frac{\hat{\sigma}}{\sqrt{n}}; \bar{Y} - \bar{X} + q_{T(n+m-2)}^{1-\alpha/2} \frac{\hat{\sigma}}{\sqrt{n}} \right]$$

- ▶ Asymptotique (n grand et sans l'hypothèse gaussienne), on utilise le TLC + Slutsky

$$T \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$$

et on construit tests et ICs à partir de la loi asymptotique

Intervalle de confiance

Introduction

Définition

Construction

Le mot de la fin

Préparation à l'examen... Check-list

- ▶ feuille A4 manuscrite + calculatrice
- ▶ Exercices refaits (corrigés sur le site pédagogique via synapse)
- ▶ Compétences attendues :
 - ↪ Construire un estimateur par les méthodes du maximum de vraisemblance et des moments
 - ↪ Comparer des estimateurs
 - ↪ Etudier l'asymptotique
 - ↪ Construire l'IC d'un paramètre et en interpréter le résultat
 - ↪ Construire un test et en interpréter le résultat ; calculer une puissance, calculer et utiliser une p-value.
 - ↪ Construire un test UPP
- ▶ une demi-heure de questions/réponses de 8h30 à 9h00 avant l'examen

Merci de votre attention!